

Félévi NagyHF dokumentáció

Üzleti Intelligencia Labor

Félév: 2026 tavasz

Movie performance analytics

Kalocsa Ádám - (XCIWI4)

kalocsaadam@edu.bme.hu

Anyagok elérhetősége

Forráskód (SSIS package, reportok, adathalmazok, sql táblák létrehozó scriptje):
<https://github.com/kalocsaadi/Movie-performance>

Adatelemzés:

<https://colab.research.google.com/drive/1QlQjOxt5XBzsOcWXekJvberFXocKE-pY?usp=sharing>

Videó:

<https://drive.google.com/file/d/1BXMwB4uLmxz4d2fQf24RnLbzqxzdUmLX/view?usp=sharing>

ETL

Az ETL folyamatokat a Microsoft termékcsalád eszközeinek alkalmazásával valósítottam meg. Magát a transzformációs folyamatokat az SSIS segítségével hoztam létre, az eredményként kapott adattáblákat mssql-ben tároltam el. A filmek adatait tartalmazó CSV adatfájlt négy részre daraboltam, ezzel lehetővé téve az adathalmaz inkrementális feltöltését, ezzel lehetővé téve a reportok adatforrásainak folyamatos bővülését.

A specifikációban meghatározott ETL folyamat 4 fázisa helyett a megvalósítás 5 folyamatot tartalmaz, amelynek okát a dimenzió táblák feldolgozásának szeparációja adja a tény tábla létrehozásától, hiszen azokra már szüksége van a megfelelő kapcsolatok létrehozása érdekében. Az alábbiakban az ETL folyamatok ütemezését és belső működését mutatom be a bemenetektől egészen a kialakított eredménytáblákig.

Ütemezés

A folyamatot lebonyolító package rendelkezik két paraméterrel, az első MovieFilePath névre hallgat, típusa string, míg a második FullReload elnevezésű boolean változó. Ezen változók teszik lehetővé, hogy az adott folyamat során meghatározhassuk, hogy melyik film részleteket tartalmazó fájlrészletet szeretnénk betölteni, illetve, hogy az adott folyamat elején teljesen kiürítjük-e a filmtárat vagy sem. Ez utóbbit úgy valósítottam meg, hogy a nyers adatokat tároló film adattáblát feltételesen törölöm a paraméter alapján.

Az ütemezés megvalósításához telepítettem az SSIS csomagomat az SQL adatbázisom integrációs szolgáltatások katalógusába. Ezt követően az SQL Server Agent segítségével létrehoztam egy új munkát, amelynek feladata az adathalmaz részenként történő feltöltése. Úgy alakítottam ki a lépéseket, hogy minden feltöltést követően várjon egy percet az Agent a következő betöltés elindításáig. Ennek célja a bemutatás során elvárt adatfrissítés prezentálásának elősegítése, a gyakorlatban természetesen ezek a várakozások elkerülhetőek. A package két paraméterét kihasználva megadom minden lépésnek a betöltendő fájl elérési útvonalát, illetve beállítom, hogy az folyamat futása előtt kiürítésre kerül a nyers tábla, de ez természetesen a későbbi lépések esetén nem történik meg. Az így kialakított munkafolyamat időzíthető lenne konkrét időpontra, de a bemutatás érdekében jelenleg manuálisan indítom el a folyamatot.

ETL 1 - Adatbetöltés

Ennek a lépésnek a célja a bemenetként kapott CSV adatfájlok beolvasása a nyers adatok tárába. A MovieFilePath változó segítségével az ETL beolvassa az film részleteket tartalmazó fájlt, továbbá betölti a megtekintési időket tartalmazó adathalmazt is. A folyamat a Flat file source blokkok segítségével beolvassa a fájlokat, amely során beállítja az adathalmazok elemeinek típusát.

A film részletek betöltése során az alapértelmezett szöveges típus helyett a date_x mező dátum típusú, míg a score, revenue, budget értékek decimális besorolást kaptak. A többi ugyan szöveges mezőnél is szükséges volt a mezők méretének módosítása. A megtekintéseket tartalmazó fájlban az értékek aposztrófok között helyezkedtek el, ennek eltávolítása után a premier időpontja egész típust kapott. Ebben az állapotban a rank még szöveges tartalomként került eltárolásra, hiszen tartalmaz egy pontot.

A nyers adatok táblába történő mentése előtt a film adatok egy duplikáció ellenőrzésen esnek át. Fontos itt kiemelni, hogy az ellenőrzés két lépcsős, hiszen azonos nevű filmek szerepelhetnek a tárolóban, ezért szükséges a kiadás időpontjának vizsgálata is. Ezt követően az adathalmazok a számukra kialakított MoviesRaw és WatchtimeRaw táblákban kerülnek eltárolásra.

ETL 2 - Tisztítás

Ezen folyamat során mindkét adathalmaz adattisztításon, mező beszűráson és típuskonverzióon esnek át párhuzamosan. Mindkét folyamat elején a nyers adatokat tartalmazó táblákat kerülnek beolvasásra az ADO NET források segítségével, illetve ezt követően mindkét folyamat átesik egy film cím normalizálási folyamaton. Ezen lépés során kerül kialakításra a Normalized_title mező, amely kulcsfontosságú szerepet fog játszani az adatok összekapcsolásában, hiszen normalizálás nélkül a két adatforrás eltérő módon tárolhatja a címeket.

A film részletek esetében a címen túl itt kerül kiszámításra a kiadás éve is, amely szintúgy a kapcsolat kialakításához lesz szükséges. Ezt követően megtisztításra kerül a felsorolásként tárolt zsanra mező is, a tagoló szóköz eltávolításra kerül, ezzel megkönnyítve a későbbi szeparációs folyamatot. Ezt követően a film bevételének és kiadásának mutatói kerülnek átalakításra egész típusra, majd ezt követően a profit és ROI értékek kiszámítása következik. Az ROI a definíciója szerint kerül kiszámításra, a bevétel és kiadás immáron egész értékek segítségével: $(\text{bevétel} - \text{kiadás}) * 100 / \text{kiadás}$, azonban a tárolás előtt még az így kapott decimális érték egy vizsgálaton esik át. Az adathalmazban előfordul bizonyos filmek esetén, hogy a kiadás minimális (pl. 7), viszont a bevétel „normális” értéket vesz fel (több száz millió). Ilyen esetekben a kapott ROI borzasztóan magas értéket venne fel, amely durván elhúzná a mutató átlagát, ennek elkerülése érdekében az ROI mezőt egy maximum 2000%-os érték felvételére korlátoztam.

A megtekintéseket tartalmazó nyers adathalmazból ezen folyamat során távolítom el a számunka nem kívánatos TV műsor típusú rekordokat egy feltételes szétválasztás blokk segítségével. Ezt követően a rangsor itt kerül átalakításra szám típusra a pont kiszűrésével, továbbá itt kerülnek átalakításra a megtekintési időket tartalmazó mezők is, a bennük szereplő vesszők eltávolításával.

Ezen átalakításokat követően a számunkra felesleges mezők kiszűrésével eltárolásra kerülnek az adathalmazok a MoviesStage és WatchtimeStage adattáblákba.

ETL 3 – Dimenzió táblák kialakítása

Az előző folyamat által létrehozott MoviesStage tábla tartalma kerül feldarabolásra. Az első folyamat a film részletek és ország, míg a második a zsanra dimenzió táblák kialakításáért felelős.

Az első folyamat szimplán lekérdezi a tábla tartalmát majd multicast segítségével két irányba továbbítja tartalmát. Az első ág szimplán a film címének, kiadási idejének, leírásának, szereplőjeinek, nyelvének és kiadási állapotának adatait eltárolja az erre kialakított DimMovie táblába. A másik ág az országok monogramjait tartalmazó dimenzió kialakításáért felelős, amely egy aggregációs blokk segítségével kerül megvalósításra, amelyben a rekordok az ország azonosító alapján kerülnek csoportosításra. Az így kapott egyedi értékek a DimCountry táblába kerülnek eltárolásra.

A második folyamat betöltési lépése egyedi, a tábla egyszerű betöltése helyett SQL parancs segítségével kerülnek beolvasásra a rekordok, amely során a CROSS APPLY STRING_SPLIT segítségével a zsanra mező vesszővel elválasztott értékei külön sorba kerülnek szétválasztásra. Az így kapott rekordok az ország dimenzió létrehozásához hasonló módon egy csoportosításon esik át, amelynek az egyedi kimeneti értékei a DimGenre táblába kerülnek elmentésre.

ETL 4 – Tény és kapcsolótáblák kialakítása

Ezen transzformációs folyamat három ágból indul, céljuk a DWH csillag struktúrájának közepét adó tény tábla és a zsanrához kapcsolódást biztosító kapcsolótábla kialakítása.

A bal oldali részfolyamat mindkét stage adathalmaz beolvasása kezdi meg működését. Ezt követően mindkét tábla adatai egy rendezésen esnek át a normalizált cím alapján, előkészítve ezzel az összekapcsolás folyamatát. A rendezést követően egy merge join blokk segítségével rendezem egymáshoz a film és megtekintési adatokat left join megvalósítással, hogy azon filmek is bekerüljenek a végleges adathalmazba, amelyek nem rendelkeznek megtekintési adatokkal. Az egyesítést követően két lookup folyamat kerül végrehajtásra. Ezek egy ole db kapcsolat segítségével megkeresik az adott filmhez tartozó korábban dimenzió táblákba eltárolt adataikat, majd eltárolják ezek azonosítóit. Ez követően a tény tábla feltöltésre kerül a kialakított tartalommal.

A jobb oldali részfolyamat a zsanrákat a tény táblához kötő kapcsolótábla kialakítását végzi. A harmadik ETL folyamathoz hasonlóan itt is szeparálva kerülnek lekérdezésre a zsanrák, majd a tisztított zsanra név mezőt használva megkeresésre kerül az összes egy adott filmhez kapcsolódó zsanra azonosítója. A kigyűjtött film-zsanra azonosítópárok a BridgeMovieGenre táblában kerülnek eltárolásra.

ETL 5 – Aggregált táblák létrehozása

Ez a folyamat ugyan egy kezdeti tény tábla beolvasással kezdődik, ezt követően három különböző ágra oszlik, annak érdekében, hogy minden részfolyamat csak a számára szükséges dimenzió táblákat kelljen beolvasnia.

Az első részfolyamat a tény tábla azonosítója alapján kikeresi a film részleteket tartalmazó rekord adatait, majd ezt követően további két részre bomlik. Az első ág év szerint, míg a második ág hónap szerint csoportosítja az adatokat, az ehhez szükséges kinyert mező létrehozását követően. A folyamatok eredményei a számukra létrehozott aggregált táblákban kerülnek eltárolásra.

A második részfolyamat egy zsanra szerinti aggregációt valósít meg. Ehhez egy kétlépéses lookup műveletet hajt végre: az elsőben kikeresi az összes az adott filmhez tartozó zsanra azonosítóját a

kapcsolótáblából, majd ezt követően megkeresi az így kinyert zsanrák nevét a dimenziótáblájából. Az adatgyűjtést követően a folyamat aggregálja a film teljesítményéhez kapcsolódó adatokat, majd elmenti azokat.

A harmadik folyamat az ország szerinti aggregáció létrehozásáért felelős. Itt kikeresésre kerül a filmhez tartozó országazonosító monogramja, majd ez mentén összesíti a film teljesítményt és menti tartalmát.

Report

Az adatok megjelenítése érdekében 4 különböző reportot hoztam létre a PowerBI segítségével, amelyek az adathalmaz különböző dimenziói szerint vizsgálják a filmeket. A reportok létrehozása során igyekeztem az egységes és igényes megjelenés megvalósításában. Minden elemet megfelelő szín, szegély és magyarázó szöveggel láttam el, a könnyű értelmezhetőség érdekében.

KPI dashboard

A KPI dashboard célja a jelenleg betöltött filmadatok összesített értékeinek megjelenítése. A report elkészítéséhez a filmek teljesítményeit, részleteit és kiadási országukat tartalmazó táblákat olvastam be.

A report felső sorában a filmek száma, összesített bevétele és megtekintési ideje, átlagos pontszáma, illetve átlagos ROI értéke található kártya formátumban, amelyben mindegyik tartalmazza a megfelelő értéket, magyarázó szövegét és mértékegységét. Ez alatt a filmek évekre lebontott bevételeit és kiadásait tartalmazó oszlopdiagram található. Mellette egy kitöltött térkép került elhelyezésre, amelyen a betöltött filmek származási helyei láthatóak színezett formátumban. A report dinamizmusát az alsó két diagram adja: interakció nélkül a teljes adathalmaz megjelenítésre kerül, az oszlopdiagramra kattintva a felhasználó kiválaszthat egy adott évet, ekkor csak azon filmek összesített adatai és helyszínei kerülnek ábrázolásra. A térképre kattintva a felhasználó ország specifikus adatokat tekinthet meg, megvizsgálhatja az adott országban kiadott filmek bevételi adatait, illetve az oszlopdiagrammon megtekintheti, hogy az adott ország filmjei az adott évben termelt bevétel és kiadás mekkora részét teszik ki.

Zsanra összesítő report

Ez a report az adatokat a zsanrák szerinti csoportosításban vizsgálja. A report megvalósításához betöltöttem a filmek teljesítményeit, zsanraikat és részleteit tartalmazó táblákat, utóbbira a kiadási időpont miatt van szükség, amelyet az időszíves szűrő használ fel.

Az oldalon megjelenítésre kerül az aktuális szűrési kritériumok alapján kiszámított összesített bevétel és profil, amelyek kártya formában jelennek meg. Alattuk egy zsanra alapján csoportosított bevételi összesítőt tartalmazó sávdigram került elhelyezésre. Mellette egy megtekintéseket tartalmazó kördiagramot láthatunk, amely zsanra felbontásban mutatja be a filmek nézésére fordított időt. Ezen diagram alatt egy oszlopdiagram kapott helyet, amely a filmek átlagos pontszámát sorrendezi zsanra szerinti csoportosításban.

A report dinamikus viselkedését a különböző zsanra adatok kiválasztásával történő szűrésen túl egy kiadási időt meghatározó slider segíti. Ezen szűrő segítségével lehetőség van beállítani egy időszíves,

amelynek eredményeképpen csak az ezen időintervallumban kiadott filmek kerülnek megjelenítésre, kiértékelésre a reportban.

Idő alapú report

Az idő alapú report a filmek kiadási ideje alapján vizsgálja a teljesítmény mutatóit. A report létrehozásához szükséges volt a filmek teljesítményeit, zsanráit és részleteit tartalmazó táblákat, a zsanra adatokat a gombszűrő alkalmazza.

A report első oldalán megjelenítésre kerül a filmek bevételeinek, kiadásának és profit termelésének mutatói évek szerint rendszerezve. Alatta egy fánk diagram található, amelynek feladata éves csoportosításban megjeleníteni a filmek megtekintésével előtött órák számát. A lap jobb alsó sarkában egy toplista található, amelyen megtekinthető az aktuális szűrési feltételek alapján legtöbb profitot termelő filmek és azok profitmutatója.

Az oldalon az évek kiválasztásával történő szűrésen túl, elhelyeztem egy akár több zsanra kiválasztására lehetőséget adó gomb szűrőt, amellyel a felhasználók mind a grafikonok, mind a toplista értékeit szűrhetik.

A report egy kétlépcsős lefűrási funkcióval rendelkezik. Egy adott évet megjelenítő diagram értékre kattintva a felhasználó lefűrhat a második oldalon található diagramra, amely az első oldalon megegyező módon film költségvetési adatokat jelenít meg, de immáron havi felbontásban a kiválasztott éven belül. Ha a felhasználó mégbeljebb szeretne menni, akkor az adott hónapra kattintva egy ismételt lefűrás kezdhető meg, amelynek eredményét a report harmadik oldala mutatja. Itt már az adott év adott hónapján belül, összesítés nélkül az adott hónapban kiadott filmek pontos kiadása, bevétele és profitja tekinthető meg.

Részletek, toplista report

A report két oldalból áll, az elsőt a felhasználó lehetőséget kap film alapadatok keresésében különböző szűrők, filterek segítségével, míg a második oldalon toplisták találhatóak időszáv szerinti tartományban.

Az első oldal tetején két szűrő található. A bal oldalon egy bemenet slicer található, amely lehetővé teszi a felhasználók számára a filmek közötti, cím alapján történő keresést. A jobb oldalon egy gomb csoport található, amely a filmek kiadási állapota alapján képes a találatokat pontosítani. A szűrők alatt egy táblázat található, amely megjeleníti a film alapadatait (cím, kiadási év, pontszám, leírás, szereplők és kiadási nyelv). A táblázat tetszőleges oszlop alapján rendezhető növekvő, csökkenő sorrendbe.

A második oldalon film toplisták találhatóak egy időintervallum szűrővel. A bal oldalon az adott kritériumoknak megfelelő top 25 legmagasabb pontszámmal rendelkező film adatai találhatóak meg, míg a jobb oldalon a legtöbb megtekintési idővel rendelkező filmek listája található. Mindkét táblázat rendszerezhető a tartalmazott oszlopok alapján.

Adatelemzés

Adatelemzési feladatomban a filmipar jövőbeli bevételeit igyekszek megjósolni idősoros elemzés alapján. A feladatomat google colab projektben valósítottam meg, amelynek készítése során kimagasló figyelmet fordítottam a kódminőségre. A folyamat számos logikai fejezetre került

felbontásra a könnyű követhetőség és végrehajtás céljával, továbbá minden lépés felett magyarázó szöveg található, amely leírja azon lépés célját és esetleges tapasztalatait.

Creating environment

Ez a fejezet a projekt során alkalmazott függőségeket importálja. Ebbe tartozik a numpy, pandas adatfeldolgozásra, matplotlib és seaborn grafikonok megjelenítésére, illetve a tensorflow és standardscaler modellezésre és skálázásra.

EDA

Ebben a fejezetben kerül megvalósításra az adathalmaz beolvasása és előzetes elemzése pandas segítségével. Az adathalmaz beolvasását követően egy seaborn heatmap segítségével megvizsgálom a hiányzó adatokat, a grafikon megerősíti, a becsléshez szükséges mezők nem tartalmaznak üres mezőket. Ezt követően átalakítom a dátumot tartalmazó mezőt dátum típusa majd ezt követően megjelenítem grafikonokon a megjelenített filmeket, illetve az összesített bevételt, amelyet megpróbálok megbecsülni. A film kiadási grafikon kimutatja, hogy a filmek erősen a 2020-as évek utánra összpontosulnak, ezt majd figyelembe kell venni a tanítási folyamat során.

A következő diagramokkal a bevétel kapcsolatát, illetve annak eloszlását vizsgálom. A trendvonalak kimutatják, hogy ugyan van valamennyi korreláció a film bevétel és kiadás között ez nem kimagasló. Az eloszlásvizsgálat kimutatja, hogy a filmek túlnyomó többsége relatív kevés bevételhez jut, amíg néhány film nagyot kaszál. Ez problémát jelenthet, hiszen ezek a kiugró értékek elhúzzák a modellünket, ennek csökkentése érdekében a filmek bevételét egy logaritmikus transzformációnak fogom alávetni.

Feature extraction

Ezen fejezetben a modell tanításához szükséges adatstruktúrát állítom elő. Létrehozom az ROI kiszámított értéket, majd a film adatokat csoportosítom kiadási hónap szerint, annak érdekében, hogy idősoros elemzésnek vethessem alá azt. Ezt követően logaritmikus transzformációnak vetem alá a bevétel mezőt az EDA tapasztalatok alapján.

Ezek után kitöltöm az üres hónapokat, értékeit interpoláció segítségével határozom meg. A hónapot kódolom trigonometrikus (sin, cos) függvények segítségével, majd kidobom a táblából a felesleges adatokat.

Splitting, Scaling and Sequencing

A fejezetben az adat átalakítását végzem a modell számára felhasználható formátumba. Először kialakítom az EDA tapasztalatok alapján a tanító, validációs és teszt adathalmazokat. Ezt követően skálázom az adatokat annak standardizálása érdekében.

Model building, training, validating, testing and visualizing

A következő két fejezet az LSTM és GRU architektúrájú modellek építésével, tanításával és kiértékelésével foglalkozik. Először a model rétegek kerülnek meghatározásra, majd a model tanításon esik át a paramétereknek megfelelően. Tanítást követően a validációs hiba mozgása kiértékelésre kerül, majd megtörténik a becslés. Mindkét esetben a becslést vizuális módon meg is jelenítem.

Evaluating results

Ez a fejezet a tanítás során szerzett tapasztalataimról számol be szöveges formában is. Itt fogalmazom meg, hogy ugyan egy bizonyos szintig követhető a filmipar mozgása, a hirtelen ugrásszerű mozgás nem megjósolható, főleg jelen adathalmaz erős 2020-as évek körüli összpontosításával.